BERT 蒸餾示範專案

專案簡介

本專案示範如何使用 bert-large-uncased 模型,在 SST-2 (Stanford Sentiment Treebank) 資 料集上進行 fine-tune, 並透過知識蒸餾技術訓練 bert-base-uncased 學生模型, 達到更輕量 化的應用。

主要特點

• 知識蒸餾:利用大模型(教師)訓練較小的模型(學生)。

• 效能優化:減少計算資源需求,適合實際部署。

• 簡單易用:透過 Python 腳本即可快速執行完整流程。

專案結構

bert-distillation

├── distilled-bert.py # 模型蒸餾程式

— trainer_teacher.py

── pyproject.toml

─ requirements.txt

├── LICENSE

-- README.md

└─ data/

教師模型訓練程式

依賴管理檔案

依賴安裝檔案(選擇性)

授權條款

本說明文件

訓練與測試資料集 (請手動下載)

環境需求

- Python 3.7 以上
- torch , transformers , datasets , accelerate
- 建議使用 Poetry 來管理套件依賴

安裝 Poetry:

```
pip install poetry
```

安裝專案依賴:

Bash

Bash

poetry install

或者使用 pip:

```
pip install -r requirements.txt
```

Bash

訓練流程

1. 複製專案

```
git clone http://gitlab.thi.com.tw/jell/bert_distillation.git
cd bert-distillation
```

Bash

2. 教師模型訓練

執行指令如下:

```
Bash python trainer_teacher.py --data_path ./data/sst2 --output_dir ./models/
```

3. 學生模型蒸餾

執行以下指令:

```
python distilled-bert.py --teacher_model ./models/teacher --output_air ./
```

蒸餾演算法詳細說明

1. 軟標籤 (Soft Label) 與溫度 (Temperature)

• 從教師模型 (bert-large-uncased) 輸出 logits,經由「溫度參數」T 進行縮放,計算出軟

標籤。

公式:

$$p_{teacher}(y \mid x) = \operatorname{softmax}\left(\frac{z_{teacher}}{T}\right)$$

其中 Zteacher 為教師模型 logits。

• 當 T > 1,分布更平滑,學生模型可學習更細微的資訊。

2. KL Divergence 損失

- 學生模型 (bert-base-uncased) 產生 logits,同樣使用溫度 T 產生軟標籤。
- 與教師的軟標籤透過 KL 散度 (Kullback-Leibler Divergence) 進行對齊。
- 目標為最小化:

$$L_{KL} = \sum_{y} p_{teacher}(y \mid x) \log \frac{p_{teacher}(y \mid x)}{p_{student}(y \mid x)}$$

3. 硬標籤 (Hard Label) 交叉熵損失

- 學生模型同時學習原始資料的真實標籤 (0/1)。
- 損失函數結合軟標籤和硬標籤:

$$L_{total} = \alpha \cdot L_{KL} + (1 - \alpha) \cdot L_{CE}$$

其中 L_{CE} 是交叉熵損失。

評估與應用

執行模型評估:

 $bash\ python\ evaluate.py\ --model\ ./models/student\ --data_path\ ./data/sst2/test$

常見問題與解決方案

1. 資料集下載

```
from datasets import load_dataset
dataset = load_dataset("stanfordnlp/sst2")
dataset.save_to_disk("./data/sst2")
```

Python

2. 模型下載失敗

授權條款

本專案採用 MIT License,詳細內容請參閱 LICENSE。

聯絡方式

如有任何問題,請聯絡 jell@thi.com.tw。